12.1 Tokenization

- input_ids: vector số nguyên chứa chỉ số của từng token (.) bộ từ điển của pretrained model để tra cứu từng embedding
- attention_mask: vector nhị phân giúp cơ chế self-attention bỏ qua các vị trí padding ko cho chúng ảnh hưởng → biểu diễn ngữ cảnh của câu.

14. Experiment 1

- Pretrained chỉ: đầu với biểu diễn ngữ cảnh đã có cấu trúc ngữ nghĩa từ kho dữ liệu lớn & đc tinh chỉnh nhẹ. From scratch học biểu diễn hoàn toàn từ (.) sẽ ngẫu nhiên, chỉ bám sát vào các từ khoá xhiện (.) tập train.

CRABIT

Được quét bằng CamScanner

- Pretrained cần rất ít dữ liệu nhãn còn from scratch cần dữ liệu lớn mới thoát khỏi mức đoán mò
- ~~Cùng 4,37M tham số và 179, 52 MiB VRAM~~
- Pretrained + fine-tuning train nhanh hơn, tốn ít RAM CPU hơn và ko tốn chi phí pretraining từ đầu
- Đúng ở mức ít dữ liệu (10% - 25%)

15. Experiment 2

- Dù đông băng, pretrained encoder vẫn trích xuất được ngữ nghĩa + cú pháp tổng quát vào vector. Tầng classification head vẫn được huấn luyện để học biên phân tách tuyến tính trên đặc trưng cố định đó,
- Đặc trưng pretrained gốc chỉ tối ưu cho MLM tổng quát nên ch tách biệt tốt các phức tạp. Mở khoá toàn bộ tham số giúp truyền ngc gradient qua toàn mạng để self-attention tự điều chỉnh (:) về theo từ khoá / ngữ cảnh.

16. Experiment 3

Pretraining có giúp mình sd dữ liệu downstream hiệu quả hơn rõ rệt
- 10% data: pretrained đạt acc = 69,16% (:) khi from scratch bị suy biến thành đoán mò
- 10% - 25%: pretrained đạt đỉnh sớm ở 25% data - ngang mức 100% data + vẫn vượt from scratch
- 50% - 100%: Pretrained bão hoà sớm, from scratch cần tới 50% - 100% data mới bắt kịp.

Được quét bằng CamScanner

17. Experiment 4

- Về mặt hiệu năng: giúp cải thiện liên tục hiệu năng vì giữ lại đc ngữ cảnh ở các câu chốt ở cuối bài review dài
- Tăng sequence length kp lúc nào cũng tốt

=> Độ phức tạp tính toán: cơ chế self attention có độ phức tạp KG & tgian tăng bậc 2 theo độ dài chuỗi T

=> Tiêu thụ tài nguyên

=> Nhiều thông tin.

18 Experiment 5:

Pretrained model ko có nghĩa là dữ liệu mọi domain. Dù mô h. pretrained sở hữu khả năng chuyển giao tri thức chung tốt nhờ các từ vựng cực cốt lõi nó vẫn bị ảnh hưởng bởi hiện tượng lệch p^2 do sự ≠ biệt về thuật ngữ & văn phong đặc thù

Được quét bằng CamScanner